

Aplicação de Técnicas de Machine Learning na Classificação de Gêneros Musicais em Plataformas de Streaming

Autores: Gabryella Santos Pinho · Louie Nery Silva · Maria Eduarda Rita Marques Noleto · Nathanael Victor Paiva Magno · Ramon Miguel Rosa Pereira Ataides

Orientador: Prof. William Roberto Malvezzi · **Instituição:** Universidade Católica de Brasília (UCB) · **Brasília, 2026**

Introdução

O Problema


O crescimento exponencial de faixas disponíveis em plataformas de streaming tornou a classificação manual de gêneros musicais inviável em escala. Soluções automatizadas são uma necessidade operacional urgente.

Motivação

- A categorização precisa é o alicerce dos sistemas de recomendação
- Recomendações relevantes aumentam o engajamento e a retenção do usuário
- Impacto direto na receita das plataformas

Objetivo Central

- Desenvolver e comparar modelos de ML: **Naive Bayes**, **Árvore de Decisão** e **Random Forest**
- Avaliar a implementação em **Python** e **R** lado a lado



Fundamentação Teórica: Music Information Retrieval (MIR)

MIR é uma área interdisciplinar que combina **processamento de sinais digitais**, ciência da computação e musicologia para extrair informações estruturadas diretamente de arquivos de áudio.

O que é MIR

- Análise automática de conteúdo sonoro
- Extração de padrões de timbre e harmonia
- Identificação de gênero sem intervenção humana

API do Spotify

- Traduz ondas sonoras em atributos numéricos
- Fornece os chamados **Audio Features**
- Base de dados estruturada para modelos de ML

Análise Automatizada

- Modelos MIR analisam padrões acústicos complexos
- Escalonável para milhões de faixas
- Elimina vieses da classificação subjetiva humana

Algoritmos de Machine Learning Utilizados

Três algoritmos foram selecionados com base em suas características distintas, permitindo uma análise comparativa abrangente sobre a tarefa de classificação multiclasse de gêneros musicais.

$f(x)$

Naive Bayes

- Baseado no **Teorema de Bayes**
- Assume independência entre variáveis
- Lida bem com a subjetividade dos gêneros via probabilidades
- Alta velocidade de treinamento



Árvore de Decisão

- Estrutura de **fluxograma hierárquico**
- Realiza perguntas sucessivas sobre atributos
- Ex: *energia* > 0.8?
- Alta interpretabilidade do modelo



Random Forest

- Método **ensemble** de múltiplas árvores
- Resultado definido por votação majoritária
- Reduz significativamente erros de generalização
- Robusto a overfitting

R vs. Python na Ciência de Dados

LINGUAGEM R

Análise Estatística e Exploração


- Foco em **análise estatística** descritiva e inferencial
- Ecossistema robusto: **ggplot2**, **caret**, **e1071**
- Visualizações de alta qualidade para compreensão de padrões
- Preferido no meio acadêmico e em pesquisas exploratórias

LINGUAGEM PYTHON

Implementação e Produção

- Versátil, escalável e com ampla adoção na indústria
- Biblioteca **scikit-learn** para pipelines de ML
- Ideal para deploys de modelos em produção
- Integração facilitada com APIs e bases de dados

- ❏ **Uso Estratégico:** R para compreensão aprofundada dos padrões acústicos; Python para construção, validação e aplicação dos modelos classificadores.



Metodologia e Base de Dados

Dataset Utilizado

Spotify Music Dataset — obtido via Kaggle. Contém metadados e características acústicas extraídas diretamente pela API do Spotify, cobrindo múltiplos gêneros musicais.

Estratégia Experimental

- **70%** dos dados para treinamento (aprendizado do modelo)
- **30%** dos dados para teste e validação
- Semente aleatória (*seed*) idêntica em R e Python para garantir **reprodutibilidade**

Variáveis-Chave (Audio Features)

Speechiness

Presença de palavras faladas na faixa

Acousticness

Nível de confiança de que a faixa é acústica

Valence

Positividade musical: alegria vs. tristeza

Danceability

Adequação da música para dançar

Energy

Intensidade e atividade perceptiva

Tempo

Velocidade da música em BPM

Avaliação de Desempenho: Métricas e Resultados

A avaliação empírica dos modelos foi conduzida por meio de métricas consolidadas na literatura de aprendizado de máquina, garantindo uma análise comparativa rigorosa e objetiva.



Acurácia

Proporção total de classificações corretas sobre o conjunto de teste. Indicador geral do desempenho do modelo.



Precisão & Revocação

Precisão mede a taxa de verdadeiros positivos entre as predições positivas. Revocação mede a taxa de positivos corretamente identificados.



F1-Score

Média harmônica entre precisão e revocação. Essencial para avaliar modelos em datasets com classes desbalanceadas.



Matriz de Confusão

Ferramenta visual que identifica erros e acertos por categoria de gênero, revelando padrões de classificação incorreta entre algoritmos.

Contribuições e Conclusão

Resultados Obtidos


- Identificação do algoritmo com **maior assertividade e robustez** para classificação de gênero
- O **Random Forest** demonstrou desempenho superior em termos de generalização
- Comparação direta e reprodutível entre Python e R validada pela semente fixa

Contribuição para o Ecossistema

- Organização eficiente do catálogo musical em plataformas de streaming
- Melhora mensurável na **navegação e descoberta musical** pelo usuário
- Integração estratégica R + Python como referência metodológica
- Base empírica para decisões em sistemas de recomendação

Trabalhos Futuros

- Expansão para modelos de Deep Learning (CNNs em espectrogramas)
- Inclusão de dados de áudio bruto além de metadados



Referências e Agradecimentos

Referências Principais

Spotify for Developers — Web API Audio Features Documentation. Disponível em: developer.spotify.com

Kaggle — Spotify Music Dataset. Base de dados pública utilizada para treinamento e validação dos modelos.

Scikit-learn Documentation — Machine Learning in Python. Pedregosa et al., JMLR, 2011.


Tzanetakis & Cook (2002) — Musical Genre Classification of Audio Signals. IEEE Transactions on Speech and Audio Processing.

Agradecimentos

Agradecemos ao **Prof. William Roberto Malvezzi** pela orientação técnica e suporte metodológico ao longo do desenvolvimento deste trabalho.

À **Universidade Católica de Brasília (UCB)** pelo ambiente acadêmico e infraestrutura disponibilizados.

Às plataformas **Kaggle e Spotify** pelo acesso à base de dados que viabilizou esta pesquisa.



Esta pesquisa demonstra que técnicas de Machine Learning, quando aplicadas com rigor metodológico e comparação linguística estruturada, representam uma solução eficaz e escalável para o desafio da classificação automática de gêneros musicais em plataformas de streaming.

Agradecemos pela atenção!